

LOKÁLIS MAXIMUM ELV

Ismétlés: $\min\{F(x): x \in A\} = F(x_0)$, ahol A konvex és $A^\circ \neq \emptyset$. A lokális minimum szükséges feltétele:

$$F'(x_0)(x - x_0) \geq 0, \forall x \in A$$

Tétel (lokális optimum I.):

$(x, u) \in E = C^n[0, T] \times L_\infty^r[0, T]$, ahol $T > 0$ fix

$\phi: R^n \times R^r \times [0, T] \rightarrow R^1$,

$f: R^n \times R^r \times [0, T] \rightarrow R^n$

$F: E \rightarrow R^1$

V nyílt környezete $(x_0, u_0) \in E$ -nek

Feladat:

$$F(x, u) := \int_0^T \phi(x(t), u(t), t) dt \rightarrow \min$$

Korlátozás:

$$Q = \{(x, u): \frac{dx}{dt} = f(x(t), u(t), t)$$

$$x(0) = a, x(T) = b$$

$$u(t) \in M, \text{ ahol } M \text{ konvex és } M^\circ \neq \emptyset\}$$

Lokális optimum:

$$\min_{Q \cap V} F(x, u) = F(x_0, u_0)$$

A lokális optimum szükséges feltétele:

Létezik $\lambda_0 \in R^1, \lambda_0 \geq 0$ és $\psi: [0, T] \rightarrow R^n$ abszolút folytonos függvény, hogy a λ_0 szám és a $\psi(\cdot)$ függvény közül nem mindkettő nulla, továbbá teljesül a következő differenciálegyenlet és egyenlőtlenség:

$$\frac{d\psi(t)}{dt} = -f_x^T(x_0(t), u_0(t), t)\psi(t) + \lambda_0 \phi'_x(x_0(t), u_0(t), t)$$

$$< -f_u^T(x_0(t), u_0(t), t)\psi(t) + \lambda_0 \phi'_u(x_0(t), u_0(t), t), u - u_0(t) > \geq 0, \text{ minden } u \in M \text{ és m.m } t \in [0, T] \text{ esetén.}$$

Hamilton-függvény:

$$H(x, u, \psi, t) := < f(x, u, t), \psi > - \lambda_0 \phi(x, u, t)$$

$$\dot{\psi} = - \frac{\partial H}{\partial x}.$$

Következmény:

A tétel állítása átfogalmazható a következő alakra:

$$\langle -H'_u(x_0(t), u_0(t), \psi(t), t), u - u_0(t) \rangle \geq 0$$

minden $u \in M$ és m.m. $t \in [0, T]$ esetén. De ez szükséges feltétele annak, hogy $u_0(t) \in M$ és V környezete $u_0(t)$ esetén

$$\min_{u \in M \cap V} \{-H(x_0(t), u, \psi(t), t)\} = -H(x_0(t), u_0(t), \psi(t), t)$$

teljesüljön, azaz a $H(x_0(t), u, \psi(t), t)$ függvény m.m. $t \in [0, T]$ esetén az $u = u_0(t)$ pontban elégíti ki az M halmazon az u szerinti *lokális maximum* szükséges feltételét. Innen a "lokális maximum elv" elnevezés.

Tétel (lokális optimum II.):

Feladat:

$$F(x, u) := \int_0^T \phi(x(t), u(t), t) dt + \varphi(x(T)) \rightarrow \min$$

Korlátozás:

$$Q = \{(x, u) : \frac{dx}{dt} = f(x(t), u(t), t), x(0) = a \\ u(t) \in M, \text{ ahol } M \text{ konvex és } M^\circ \neq \emptyset\}$$

Lokális optimum:

$$\min_{Q \cap V} F(x, u) = F(x_0, u_0)$$

A lokális optimum szükséges feltétele:

Létezik $\lambda_0 \in R^1, \lambda_0 \geq 0$ és $\psi : [0, T] \rightarrow R^n$ abszolút folytonos függvény, hogy a λ_0 szám és a $\psi(\cdot)$ függvény közül nem mindkettő nulla, továbbá teljesül a következő differenciálegyenlet és egyenlőtlenség:

$$\frac{d\psi(t)}{dt} = -f'_x(x_0(t), u_0(t), t)\psi(t) + \lambda_0 \phi'_x(x_0(t), u_0(t), t)$$

$$\psi(T) = -\lambda_0 \phi'_x(x(T))$$

$$\langle -f'_u(x_0(t), u_0(t), t)\psi(t) + \lambda_0 \phi'_u(x_0(t), u_0(t), t), u - u_0(t) \rangle \geq 0, \text{ minden } u \in M \text{ és m.m. } t \in [0, T] \text{ esetén.}$$

A feltételek a Hamilton-függvénnyel a lokális maximum elv alakjára hozhatók. Különbség azonban az előző feladathoz képest, hogy $\psi(T)$ -re van előírt feltétel, míg az előző feladatban ilyen nem volt. Azonban $\psi(0)$ most sem ismert, ami a problémát bonyolulttá teszi.

Következmény:

1) Ha $M = R^r$ (nincs korlátozás $u(t)$ -re), akkor $H'_u = f'^T_u(x_0(t), u_0(t), t)\psi(t) - \lambda_0 \phi'_u(x_0(t), u_0(t), t) \equiv 0$.

2) Ha $\lambda_0 > 0$, akkor mindkét oldalon oszthatunk $(-\lambda_0)$ -al és bevezethetjük a $\hat{\psi} := \psi / (-\lambda_0)$ és $\hat{H} := \langle f, \hat{\psi} \rangle + \phi$ jelölést.

Ezzel a jelöléssel $\hat{H}'_u(x_0(t), u_0(t), \hat{\psi}(t), t) \equiv 0$ és $\frac{d\hat{\psi}}{dt} = -\frac{\partial \hat{H}}{\partial x}$ m.m., ahol $\hat{\psi}(T) = \phi'(x_0(T))$.

Folytonosidejű LQ irányítási feladat:

Legyen $(x, u) \in E = C^n[0, T] \times L^\infty_r[0, T]$, $T > 0$ fix, a minimalizálandó $F(x, u)$ egy kvadratikus költségfüggvény és a rendszer folytonosidejű időben változó lineáris (LTV) rendszer:

$$F(x, u) = \frac{1}{2} \int_0^T [\langle Q(t)x(t), x(t) \rangle + \langle R(t)u(t), u(t) \rangle] dt + \frac{1}{2} \langle Q(T)x(T), x(T) \rangle, \quad \text{ahol } Q(t) \geq 0, R(t) > 0,$$

$$\frac{dx}{dt} = A(t)x(t) + B(t)u(t), \quad x(0) = x_0.$$

Alkalmazzuk a lokális maximum elvet az új formában és a diszkrétidejű esethez való hasonlóság kidomborítása céljából a $\lambda(t) := \hat{\psi}(t)$ jelölés mellett:

$$\hat{H} = \langle Ax + Bu, \lambda \rangle + \frac{1}{2} (\langle Qx, x \rangle + \langle Ru, u \rangle),$$

$$\dot{\lambda}(t) = -\hat{H}'_x = -A^T(t)\lambda(t) - Q(t)x(t), \quad \lambda(T) = Q(T)x(T),$$

$$\hat{H}'_u = B^T(t)\lambda(t) + R(t)u(t) = 0 \Rightarrow u(t) = -R^{-1}(t)B^T(t)\lambda(t).$$

Visszaírva az optimális irányítás alakját az állapotegyenletbe, a következő vegyes kezdeti és végérték problémát kapjuk:

$$\begin{pmatrix} \dot{x} \\ \dot{\lambda} \end{pmatrix} = \begin{bmatrix} A & -BR^{-1}B^T \\ -Q & -A^T \end{bmatrix} \begin{pmatrix} x \\ \lambda \end{pmatrix}, \quad x(0) = x_0, \quad \lambda(T) = Q(T)x(T).$$

Keressük a megoldást $\lambda(t) = P(t)x(t)$ alakban:

$$\dot{\lambda} = \dot{P}x + P\dot{x} = \dot{P}x + P(Ax - BR^{-1}B^T Px) = -Qx - A^T Px,$$

akkor a (P -ben kvadratikus) folytonosidejű Riccati-differenciálegyenlethez jutunk:

$$\begin{aligned} \dot{P}(t) + P(t)A(t) + A^T(t)P(t) - P(t)B(t)R^{-1}(t)B^T(t)P(t) + Q(t) &= 0, \\ P(T) &= Q(T), \end{aligned}$$

amelynek $P(t) \geq 0$ pozitív megoldását keressük. Az optimális LQ irányítás állapot-visszacsatolás, amely $P(t)$ ismeretében:

$$u(t) = -K(t)x(t), \quad \text{ahol } K(t) = R^{-1}(t)B^T(t)P(t).$$

Ha $T = \infty$ és az optimalizálási kritérium és a rendszer konstans (LTI), akkor az optimális irányítás az $u = -K_\infty x$ konstans állapotvisszacsatolás, ahol $K_\infty = R^{-1}B^T P_\infty$ és P_∞ megoldása a következő folytonosidejű algebrai Riccati-egyenletnek:

$$P_\infty A + A^T P_\infty - P_\infty B R^{-1} B^T P_\infty + Q = 0.$$

Az algebrai Riccati-egyenlet megoldására több szoftver eszköz (pl. MATLAB CST-ben `lqr`, `lqr2`) ismeretes.

Az LQ optimális irányítás mellett:

- i) $F(x, u)$ optimalizálási kritérium véges, ha (A, B) irányítható (stabilizálható).
- ii) Legyen $Q = C^T C$ (például $C := \sqrt{Q}$), akkor a zárt rendszer stabilis, ha (A, C) megfigyelhető (detektálható).

Tétel (Pontrjagin-féle maximum elv):Feladat:

$$F(x, u) := \int_0^T \phi(x(t), u(t)) dt \rightarrow \min, \quad T > 0 \text{ szabad}$$

Korlátozás:

$$Q = \{(x, u) : \frac{dx}{dt} = f(x(t), u(t)), \quad x(0) = a, \quad x(T) = b \\ u(t) \in M, \text{ ahol } M \neq \emptyset \text{ tetszőleges}\}$$

Globális optimum:

$$\min_Q F(x, u) = F(x_0, u_0), \quad T > 0 \text{ szabad}$$

A globális optimum szükséges feltétele:

Létezik $\lambda_0 \in R^1, \lambda_0 \geq 0$ és $\psi : [0, T] \rightarrow R^n$ abszolút folytonos függvény, hogy a λ_0 szám és a $\psi(\cdot)$ függvény közül nem mindkettő nulla, továbbá teljesül a következő differenciálegyenlet és egyenlőtlenség:

$$\frac{d\psi(t)}{dt} = -f'_x(x_0(t), u_0(t))\psi(t) + \lambda_0 \phi'_x(x_0(t), u_0(t))$$

$$H(x, u, \psi(t)) := \langle f(x, u), \psi \rangle - \lambda_0 \phi(x, u)$$

$$\max_{u \in M} H(x_0(t), u, \psi(t)) = H(x_0(t), u_0(t), \psi(t)) = 0$$

Következmény (bang-bang elv):

Feladat és korlátozás:

$$F(x, u) = \int_0^T \phi(x(t)) dt, \quad T > 0 \text{ szabad}$$

$$\dot{x} = g(x) + Bu, \quad x(0) = a, \quad x(T) = b,$$

$$M = \{u \in R^r : |u_i| \leq 1, i = 1, \dots, r\}.$$

Legyen $\lambda_0 > 0$, akkor a Hamilton-függvényt és a társ-differenciálegyenletet végigoszthatjuk λ_0 -lal, és elvégezhető a $H := H / \lambda_0$ és a $\psi := \psi / \lambda_0$ helyettesítés. A

Hamilton-függvénynek ezután a normalizálás után is maximuma lesz az optimális irányítás esetén. A vizsgált rendszer esetén a normalizálás után

$$H(x, u, \psi) = \langle g(x) + Bu, \psi \rangle - \phi(x),$$

$$\dot{\psi}(t) = -g'_x(x_0(t))\psi(t) + \phi'_x(x_0(t)),$$

és a Pontrjagin-féle maximum elv szerint

$$\max_{u \in M} [\langle g(x_0(t)) + Bu, \psi(t) \rangle - \phi(x_0(t))] =$$

$$= \langle g(x_0(t)) + Bu_0(t), \psi(t) \rangle - \phi(x_0(t))$$

Definiáljuk az előjelfüggvényt vektor argumentum esetén:

$$\text{sign}(x) := (\text{sign}(x_1), \dots, \text{sign}(x_n))^T,$$

akkor a Pontrjagin-féle maximum elvből következik:

$$\max_{|u_i| \leq 1} \langle u, B^T \psi(t) \rangle = \langle u_0(t), B^T \psi(t) \rangle \Rightarrow u_0(t) := \text{sign}(B^T \psi(t)),$$

Ezért az optimális irányítás $u_{0i}(t)$ komponensei minden időpontban csak ± 1 értéket vehetnek fel, tehát a negatív és a pozitív szélsőértékük között választhatnak (bang-bang). Hogy mikor melyiket kell választani, az $B^T \psi(t)$ -től függ, tehát lényegében $\psi(t)$ aktuális értékétől.

Mivel $x_0(t)$ is ismeretlen, és $\psi(t)$ meghatározásához $x_0(t)$ is szükséges, amely viszont $u_0(t)$ -től függ, ezért a bang-bang elv ugyan egyszerűsíti a problémát, de a megmaradó

$$\begin{aligned} \dot{x}_0(t) &= g(x_0(t)) + B \text{sign}(B^T \psi(t)) \\ \dot{\psi}(t) &= -g'_x(x_0(t))\psi(t) + \phi_x(x_0(t)) \end{aligned}$$

csatolt probléma, beleértve az általában kevert vagy hiányzó kezdeti és végérték feltételeket is, még ebben a viszonylag egyszerűbb esetben is numerikus szempontból kellően bonyolult marad.

Lineáris rendszer esetén kapcsolási görbék meghatározásával igyekeznek egyszerűsíteni a problémát.

Megjegyzés:

- i) Ha a kezdeti és/vagy végállapotnak az $S(x)$ felületen kell lennie, akkor ψ -nek ebben az időpontban merőlegesnek kell lennie a felület érintősíkjára (transzverzálitási feltétel).
- ii) Speciálisan, ha hiányzik a korlátozás a kezdeti és/vagy végállapotban, akkor $\psi = 0$ ebben az időpontban (azaz merőleges a teljes térre).

QP ÉS NP PROGRAMOZÁSI FELADATOK MEGOLDÁSA

KVADRATIKUS PROGRAMOZÁSI ALGORITMUSOK

A kvadratikus programozás alapfeladata a következő:

$$\min_x J(x) = \frac{1}{2} \langle Hx, x \rangle + \langle c, x \rangle + d,$$
$$x \geq 0, \quad A_1 x = b_1, \quad A_2 x \leq b_2,$$

ahol $x \in R^n$, $H \geq 0$ $n \times n$ méretű pozitív szemidefinit szimmetrikus mátrix, $b_1 \in R^{m_1}$, $b_2 \in R^{m_2}$, $J'_x = Hx + c =: g(x)$ a cél-függvény gradiense és $J''_x = H$ a célfüggvény Hess-mátrixa. A korlátozások egyenlőség és egyenlőtlenség alakjában adódtak. A minimum helyét d nem befolyásolja, ezért el is hagyható lenne.

Mivel $H \geq 0$ miatt $J(x)$ konvex és a korlátozások lineárisak, ezért a minimum szükséges feltétele nem túl szigorú feltételek teljesülésekor (pl. $Z^T H Z$ pozitív definit, lásd később) egyúttal elégséges feltétel is. A minimum szükséges feltételét a KKT-tétel adja.

Ha A_i sorait rendre $a_{i1}^T, \dots, a_{im_i}^T$ jelölik, akkor $A_1 x = b_1$ ekvivalens $a_{1j}^T x - b_{1j} = 0$ -val, $j = 1, \dots, m_1$, és $A_2 x \leq b_2$ ekvivalens $a_{2j}^T x - b_{2j} \leq 0$ -val, $j = 1, \dots, m_2$. A skalár multiplikátorral szorzott $\lambda_{1j}(a_{1j}^T x - b_{1j})$ és $\lambda_{2j}(a_{2j}^T x - b_{2j})$ korlátozások rendre felírhatók a $\langle \lambda_1, A_1 x - b_1 \rangle = \langle A_1^T \lambda_1, x \rangle - \langle \lambda_1, b_1 \rangle$ és a $\langle \lambda_2, A_2 x - b_2 \rangle = \langle A_2^T \lambda_2, x \rangle - \langle \lambda_2, b_2 \rangle$ alakban is a λ_1 és λ_2 vektor multiplikátorokkal.

Mivel $J'_x = Hx + c$ és $-x \leq 0$, ezért a minimum feltétele:

$$\begin{aligned} Hx + c - \lambda + A_1^T \lambda_1 + A_2^T \lambda_2 &= 0, \\ \lambda_i &\geq 0, \quad \lambda_i x_i = 0, \quad i = 1, \dots, n, \\ \lambda_{2i} &\geq 0, \quad \lambda_{2i} (a_{2i}^T x_i - b_{2i}) = 0, \quad i = 1, \dots, m_2, \\ A_1 x &= b_1 \end{aligned}$$

AKTÍV HALMAZ MÓDSZEREK:

1. Egyenlőség alakjában adott korlátozások

$$\begin{aligned} \min_x J(x) &= \frac{1}{2} \langle Hx, x \rangle + \langle c, x \rangle + d, \\ Ax &= b, \end{aligned}$$

ahol A $m \times n$ típusú mátrix, amelynek sorai a_1^T, \dots, a_m^T .

Egy x pontot *megvalósítható pontnak* (feasible point) fogunk nevezni, ha kielégíti a korlátozást. Ha x_0 az optimális megvalósítható megoldás és x egy (nem optimális) megvalósítható megoldás, akkor $x_0 = x + p$, ahol p -t *megvalósítható iránynak* (feasible direction) fogjuk nevezni.

Feltesszük, hogy $m < n$ és $\text{rank}(A) = m$, különben ugyanis vagy redundáns, vagy pedig ellentmondó egyenletek szerepelnének a korlátozásban. Elvben tehát $n - m$ változót ki lehet küszöbölni a változók közül. Fejezzük ki x -et az $x = Yx_Y + Zx_Z$ alakban, ahol $AY = I$ és $AZ = 0$. Ekkor $Ax = x_Y$ és $Zx_Z \in \text{kernel}(A)$. Mivel $x_0 = Yx_{0Y} + Zx_{0Z}$, $Ax_0 = AYx_{0Y} + AZx_{0Z} = x_{0Y} = b$, $x = Yx_Y + Zx_Z$ és $Ax = AYx_Y + AZx_Z = x_Y = b = x_{0Y}$, ezért $x = Yx_{0Y} + Zx_Z$ és $p = x_0 - x = Z(x_{0Z} - x_Z) =: Zp_Z$ és $Ap = AZp_Z = 0$.

A Lagrange-multiplikátor szabály szerint az optimális megvalósítható megoldás kielégíti a

$$\begin{aligned} J'_x(x_0) + A^T \lambda_0 &= Hx_0 + c + A^T \lambda_0 = 0 \Rightarrow Hx_0 + c = -A^T \lambda_0 \\ Z^T g(x_0) &= -Z^T A^T \lambda_0 = 0^T \end{aligned}$$

feltételt, ahol kihasználtuk, hogy $g(x_0) = Hx_0 + c = J'_x(x_0)$ a gradiens az optimum helyén és $Z^T A^T = 0^T$.

Legyen x egy (közelítő) megvalósítható megoldás. Mivel $x_0 = x + p$ és $p = Zp_Z$, ezért

$$\begin{aligned} \frac{1}{2} < H(x + p), x + p > + < c, x + p > + d &= \\ &= \frac{1}{2} < Hp, p > + < Hx, p > + \frac{1}{2} < Hx, x > + < c, p > + < c, x > + d = \\ &= \frac{1}{2} < Hp, p > + < Hx + c, p > + d + \frac{1}{2} < Hx, x > + < c, x > = \\ &= \frac{1}{2} < Z^T HZp_Z, p_Z > + < Z^T g(x), p_Z > + d + \frac{1}{2} < Hx, x > + < c, x >. \end{aligned}$$

Az x (közelítő) megvalósítható megoldás ismeretében az optimális x_0 megvalósítható megoldás a következő, korlátozás nélküli optimalizálási feladat megoldásaként nyerhető:

$$\begin{aligned} \min_{p_Z} J(p_Z) &= \frac{1}{2} < \hat{H}p_Z, p_Z > + < \hat{c}, p_Z > + \hat{d}, \\ \hat{H} &= Z^T HZ \geq 0, \quad \hat{c} = Z^T g(x), \quad \hat{d} = d + \frac{1}{2} < Hx, x > + < c, x > \end{aligned}$$

Az optimális megoldás a $J'_{p_Z} = \hat{H}p_Z + \hat{c} = 0$ feltételből határozható meg:

$$Z^T H Z p_Z = -Z^T g(x),$$

ahol $g(x) = Hx + c$ az eredeti célfüggvény gradiense a közelítő megoldás helyén. Ha "+" jelöli a Moore-Penrose pszeudoinverzet, akkor

$$p_Z = -(Z^T H Z)^+ Z^T g(x) \text{ és } p = Z p_Z \text{ megvalósítható irány.}$$

A módszer alkalmazásához ismerni kell egy kezdeti x megvalósítható megoldást (initial feasible point) és meg kell határozni A -nak az Y, Z felbontását. A MATLAB szolgáltatásaival $Y = \text{pinv}(A)$ és $Z = \text{null}(A)$ megfelelne, de jelentős számítási idővel jár, és kevésbé előnyös iteratív alkalmazáskor, amikor A lépésről lépésre változhat.

A QR felbontást alkalmazva a következőképp járhatunk el:

- i) Képezzük az A^T mátrix QR felbontását a MATLAB `qr` függvényével. Akkor $A^T = Q * R$, ahol Q ortonormált, R felső háromszögmátrix, és ezért $A * Q = R^T = [R_1^T \ 0]$.
- ii) $Y = Q(:, 1:m) * (R_1^T)^{-1}$
- iii) $Z = Q(:, m+1:n)$
- iv) $x = Y * b$ megvalósítható megoldás

Ha az iteráció során egy új \hat{a}^T sort kell beszúrni, mert a feltételek bővülnek, akkor

$$\hat{A} = \begin{bmatrix} A \\ \hat{a}^T \end{bmatrix} = \begin{bmatrix} R^T Q^T \\ \hat{a}^T \end{bmatrix} = \begin{bmatrix} R_1^T & 0 \\ \hat{a}^T Q \end{bmatrix} Q^T = \begin{bmatrix} \hat{R}_1^T & 0 \end{bmatrix} \hat{Q}^T,$$

ahol $\hat{Q} = QH$ és H Householder mátrix. \hat{Q} első $1, \dots, m$ oszlópa azonos Q oszlópaival, míg a többi $m+1, \dots, n$ oszlópa lineáris kombinációja Q utolsó $m+1, \dots, n$ oszlopának.

Ha az iteráció során az s -edik sort el kell hagyni A -ból, mert a feltételek száma csökken, akkor \hat{A} -nak eggyel kevesebb sora lesz, mint A -nak, ezért $\hat{A}Q = \begin{bmatrix} M & 0 \end{bmatrix}$, ahol M -nek az első $1, \dots, s-1$ sora azonos R_1^T soraival, és a maradék $s, \dots, m-1$ sorokban a diagonálisban lévő elemtől jobbra is van még egy nemnulla elem. M alsó háromszögmátrix alakra hozható síkbeli forgatás tarszformációkkal, amelyeket Q -ra jobbról kell alkalmazni. Ezek a forgatások nem befolyásolják Q utolsó $n-m$ oszlopát, ezért \hat{Z} a régi Z mátrix lesz, kiegészítve egy extra oszloppal: $\hat{Z} = \begin{bmatrix} Z & \hat{z} \end{bmatrix}$, ahol \hat{z} lineáris kombinációja Q első m oszlopának.

2. Egyenlőtlenség alakjában adott korlátozások

Legyen az optimalizálási feladat

$$\min_x J(x) = \frac{1}{2} \langle Hx, x \rangle + \langle c, x \rangle + d,$$

$$Ax \leq b,$$

ahol A $m \times n$ típusú mátrix, amelynek sorai a_1^T, \dots, a_m^T .

Ha x egy megvalósítható pont, akkor $Ax \leq b$. Határozzuk meg az aktív korlátozásokat, amelyre $a_{i_j}^T x = b_{i_j}$, $j = 1, \dots, m_x$, és helyezzünk el minden ilyen $a_{i_j}^T$ -t és b_{i_j} -t rendre egy A_1 mátrixban és egy b_1 vektorban, akkor $A_1 x = b_1$. Alkalmazzuk ezután az előző módszert az A_1 mátrixszal és a b_1 vektorral. A nem aktív korlátozások A_2 -be és b_2 -be kerülnek, tehát $A_2 x < b_2$.

Egy p irány ún. *javító megvalósítható irány*, ha $A_1 p \leq 0$ és $\langle g(x), p \rangle < 0$. Ekkor ugyanis $\lambda > 0$ esetén $J(x + \lambda p) \approx J(x) + \lambda \langle g(x), p \rangle \leq J(x)$, továbbá $A_1(x + \lambda p) = A_1 x + \lambda A_1 p \leq b_1$ és $A_2(x + \lambda p) = A_2 x + \lambda A_2 p < b_2$, feltéve, hogy $\lambda > 0$ elég kicsi. Ezért a p irányban megfelelő lépésközzel továbblépve a $J(x)$ kritérium csökken és a korlátozás is teljesül.

A $P = P^T$ mátrixot projekciós mátrixnak nevezzük, ha $P^2 = P$. Például $P = I - A_1^+ A_1$ egy projekciós mátrix, ahol A_1^+ a Moore-Penrose pszeudoinverze A_1 -nek. Ha A_1 $m_1 \times n$ méretű és $\text{rank}(A_1) = m_1 < n$, akkor $P = I - A_1^T (A_1 A_1^T)^{-1} A_1$ szintén egy projekciós mátrix. Ha P projekciós mátrix és $p = -Pg(x)$, akkor p egy javító megvalósítható irány, mivel

$$\begin{aligned} \langle g(x), p \rangle &= \langle g(x), -Pg(x) \rangle = -\langle g(x), P^2 g(x) \rangle = -\langle Pg(x), Pg(x) \rangle = \\ &= -\|Pg(x)\|^2 < 0. \end{aligned}$$

Az A_1 -hez más technikával meghatározott $p = -Z(Z^T HZ)^+ Z^T g(x)$ irány is egy javító megvalósítható irány, mivel $A_1 Z = 0$ miatt $A_1 p = 0$, és p az x pontból a minimumhoz tartozó x_0 pontba mutat, tehát ebben az irányban a kritériumfüggvény csökken.

Vigyázni kell azonban milyen α lépéshosszt választunk, mert nagy lépéshossz esetén az új pont nem biztos, hogy megvalósítható (a korlátozásokat kielégítő) marad.

Ha nem sérülnének a korlátozások, akkor az *optimális választás*

$$\alpha_{opt} = \arg \min \varphi(\alpha) = \arg \min J(x + \alpha p)$$

lenne, amiből

$$\varphi'(\alpha) = \langle H(x + \alpha p) + c, p \rangle = \langle g(x), p \rangle + \alpha \langle Hp, p \rangle$$

miatt következik

$$\alpha_{opt} = -\frac{\langle g(x), p \rangle}{\langle Hp, p \rangle}.$$

Azonban egy *maximális lépéshossz* is megadható, amelynél nagyobb lépéshossznál már az eddig teljesülő inaktív korlátozások sérülnének. Jelölje az aktív és az inaktív korlátozások indexhalmazát rendre I_{A_1} illetve I_{A_2} , akkor egy eddig inaktív korlátozás sérülni kezdene, ha $a_{2i}^T(x + \alpha p) = b_{2i}$, $i \in I_{A_2}$, ezért a maximális lépéshossz

$$\alpha_{\max} = \min \left\{ \frac{b_{2i} - a_{2i}^T x}{a_{2i}^T p} : i \in I_{A_2} \right\}.$$

Egy másik problémát a *Lagrange-multiplikátorok* okozhatnak az optimum helyén. Egyenlőtlenség alakjában adott $Ax \leq b$ korlátozások esetén

$$Hx + c + A^T \lambda = 0, \\ \lambda_i \geq 0, \quad \lambda_{2i} (a_{2i}^T x - b_{2i}) = 0, \quad i = 1, \dots, m_2.$$

Az inaktív korlátozásokhoz tartozó multiplikátorok mind nullák: $\lambda_i = 0$, $i \in I_{A_2}$, ezért a feltételek egyszerűsödnek:

$$Hx + c = g(x) = -A_1^T \lambda_1 \text{ és } \lambda_1 \geq 0.$$

Meg kell tehát oldani a $g(x) = -A_1^T \lambda_1$ egyenletrendszer λ_1 -re és ellenőrizni kell, hogy λ_1 minden komponense pozitív-e. Ha vannak negatív komponensek is, akkor célszerű elhagyni mindazon feltételt az aktív halmazból, amelyik a legnagyobb abszolút értékű negatív multiplikátorhoz tartozik. Jelölje ezt $\lambda_{1,delete} = \min \{ \lambda_{1i} : \lambda_{1i} < 0, i \in I_{A_1} \}$, akkor az elhagyandó aktív feltételek:

$$I_{delete} = \{ i \in I_{A_1} : \lambda_{1i} = \lambda_{1,delete}, i \in I_{A_1} \}.$$

A teszthez a λ_1 Lagrange-multiplikátor meghatározható $\lambda_1 = -(A_1 A_1^T)^{-1} A_1 g(x)$ alapján, vagy ha már meghatároztuk az $A_1^T = Q * R$ felbontást, akkor MATLAB környezetben balosztással is:

$$\lambda_1 = -R \setminus Q' \cdot g(x)$$

3. Kezdeti megvalósítható pont meghatározása

- i) Legyen a korlátozás $Ax \leq b$ alakú, ahol az A mátrix $m \times n$ méretű. Válasszunk egy tetszőleges x^0 kezdőpontot.
- ii) Legyen $d = Ax^0 - b$.
- iii) Ha $d = (d_1, \dots, d_m)^T \leq 0$, akkor stop (x^0 megvalósítható pont).
- iv) $d_{\max} = \max \{ d_i : 1 \leq i \leq m \}$.
- v) Legyen $\hat{x} = (x^T \ z)^T$, $z \in R^1$, $\hat{A} = [A \ \mathbf{1}_{m,1 \times 1}]$, $\hat{J}(\hat{x}) = (0 \ \dots \ 0 \ 1)\hat{x} = z$ és $\hat{x}^0 = [x^{0T} \ d_{\max}]^T$. Oldjuk meg a következő (speciális lineáris programozási, LP) *segédproblémát*: $\min_{\hat{x}} \hat{J}(\hat{x}) = z$, $\hat{A}\hat{x} \leq b$, ahol \hat{x}^0 megvalósítható induló pont a segédfeladathoz. Bármilyen, az LP feladat megoldására alkalmas módszer (szimplex, stb.) szóba jöhet, beleértve az aktív halmaz módszert is.
- vi) Legyen $\hat{x}_{opt} = (x_{opt}^T \ z_{opt})^T = \arg \min_{\hat{x}} \hat{J}(\hat{x})$ a segédfeladat optimális megoldása. Ha $z_{opt} = \hat{J}(\hat{x}_{opt}) < 0$, akkor x_{opt} az eredeti feladat egy megvalósítható pontja, mivel $a_i^T x_{opt} - z_{opt} \leq b_i \Rightarrow a_i^T x_{opt} - b_i \leq z_{opt} \leq 0, i = 1, \dots, m \Rightarrow Ax_{opt} \leq b$.

Az aktív halmaz módszeren alapuló QP algoritmus

- 1) Határozzunk meg egy induló x^0 megvalósítható irányt (lásd előző LP segédprobléma). Legyen $k = 0$.
- 2) Határozzuk meg x^k esetén az aktív és az inaktív korlátozásokat és az azokat azonosító $I_{A_1}, A_1, b_1, I_{A_2}, A_2, b_2$ jellemzőket.
- 3) Határozzuk meg a $g(x^k)$ gradienst és a p^k javító megvalósítható irányt.
- 4) Ha $p^k \neq 0$, akkor határozzuk meg $\alpha = \min\{\alpha_{opt}, \alpha_{max}\}$ értékét. Legyen az új megvalósítható pont $x^{k+1} := x^k + \alpha p^k$, $k := k + 1$ és ugrás 2)-re.
- 5) Ha $p^k = 0$, akkor ellenőrizendő, hogy teljesül-e az optimum feltétele. Ehhez meg kell határozni a λ_1 Lagrange-multiplikátort az aktív korlátozásokhoz.
- 6) Ha $\lambda_1 \geq 0$, akkor optimumban vagyunk és stop.
- 7) Ha $\neg(\lambda_1 \geq 0)$, akkor meghatározandó $\lambda_{1,delete}$ és az aktív korlátozásokból elhagyandó feltételek I_{delete} indexhalmaza. Elvégzendő az aktív korlátozások redukciója és ugrás 2)-re.

Az algoritmus minden lépésére korábban már eljárásokat dolgoztunk ki.

Nemlineáris programozási feladat (NP)

$$\begin{aligned} \min F_0(x) \\ F_i(x) = 0, i = 1, \dots, m_1, F_i(x) \leq 0, i = m_1 + 1, \dots, m \end{aligned}$$

Megoldására a QP módszert *lokálisan*, az x^k aktuális közelítés környezetében alkalmazhatjuk a következő algoritmus szerint:.

- 1) Válasszunk egy x^0 megvalósítható pontot, és legyen $k = 0$.
- 2) Linearizáljuk a nemlineáris függvényeket az x^k közelítő megoldás helyén, és vezessük be a következő jelöléseket:
 $\tilde{x} := x - x_k$, $g(x^k) := F'_{0x}(x^k)$, $H := F''_{0x}(x^k)$, $a_i^T := F'_{ix}(x^k)$, $b_i = -F_i(x^k)$, $i = 1, \dots, m$.
- 3) Alkalmazzuk az aktív halmaz módszeren és a megvalósítható irányokon alapuló QP algoritmust, de annak 4) pontjában alkalmazzunk iránymenti keresést az $\alpha \geq 0$ skalárváltozóban $\alpha = \arg \min J(\alpha p^k)$ meghatározására, és tartsuk be az $F_i(x^k + \alpha p^k) \leq 0$, $i = 1, \dots, m$ feltételt az iránymenti keresés során.
- 4) Az aktív halmaz módszer stop feltételének elérésekor legyen $x^{k+1} := x^k + \tilde{x}_{opt}$ és ugrás 1)-re, illetve valamilyen ésszerű leállási feltétel teljesülésekor (csak kicsit változó x^{k+1} , vagy a maximális iterációs szám elérése) stop.

MATLAB *Optimization Toolbox* idevágó szolgáltatásai:

A MATLAB *Optimization Toolbox* függvényeket tartalmaz a különféle optimalizálási feladatok megoldására. Az ott használt jelölésekkel a feladat elég általános alakja

$$\begin{aligned} \min f(x) \\ c(x) \leq 0, \text{ } ceq(x) = 0, lb \leq x \leq ub, \end{aligned}$$

ahol x vektor, $f(x)$ skalárértékű optimalizálási kritérium, $c(x)$ és $ceq(x)$ vektorértékű korlátozások, lb és ub az x vektor alsó illetve felső korlátja.

Általános elvként elmondható, hogy a hívásoknál 'fun' egy olyan függvénynek a neve, amelyik a bemenetként kapott x -hez meghatározza $f(x)$ értékét, míg 'nonlcon' egy másik függvény, amely $c(x)$ és $ceq(x)$ értékét határozza meg.

Ha be van kapcsolva a grad és/vagy Hessian kapcsoló az *options*-ban, (lásd *optimset*), akkor a 'fun' függvénynek ezek értékét is ki kell számítania, különben értékük véges differenciákkal vagy más módon lesz közelítve.

Ha lb vagy ub dimenziója kisebb x dimenziójánál, akkor x első komponensei közül csak annyi van alsó illetve felső korlátozásnak alávetve, amennyi lb illetve ub dimenziója, közbenső változókat pedig []-vel lehet kimaszkolni.

Ha x_0 szerepel a híváskor és megvalósítható, akkor innen indul az optimalizálás, ellenkező esetben egy kezdeti segéd-probléma automatikusan meghatározza az induló x_0 értéket.

Ha a bemeneti paraméterek között szerepel *options*, akkor ez befolyásolja a közbenső lépések listázását, x_{opt} illetve $f(x_{opt})$ pontosságát, stb.

A kimeneti paraméterek között x_{opt} a módszerrel megtalált optimális megoldás, és további információkat is lehet kérni az optimalizálás folyamatáról.

Kvadratikus programozás (QP):

$[x, fval, exitflag, output, lambda] = quadprog(H, c, A, b, Aeq, beq, lb, ub, x0, options)$

ahol az optimalizálási feladat $\min f(x) = \frac{1}{2} \langle Hx, x \rangle + \langle c, x \rangle$, $Ax \leq b$, $Aeq * x = beq$, $lb \leq x \leq ub$, a kezdeti közelítés $x0$, és *options* specifikus előírásokat tartalmaz a kereséshez (lásd *help optimset*). Ha hiányoznak feltételek, akkor azt [] segítségével kell megadni. A kimeneti paraméterek között *exitflag* egy integer, amely információt tartalmaz az algoritmus befejeződéséről (értéke 1 konvergencia esetén, 0 *options.MaxIter* elérése miatti leálláskor, stb.). Az *output* egy struktúra, amely az optimalizálás folyamatáról tartalmaz információt. A *lambda* kimeneti paraméter egy struktúra, amely a λ Lagrange-multiplikátorokat tartalmazza.

Lineáris programozás (LP):

$[x, fval, exitflag, output, lambda] = linprog(c, A, b, Aeq, beq, lb, ub, x0, options)$

ahol a feladat $\min f(x) = \langle c, x \rangle$, $Ax \leq b$, $Aeq * x = beq$, $lb \leq x \leq ub$, a kezdeti közelítés $x0$ és *options* specifikus előírásokat tartalmaz a kereséshez. A kimeneti paraméterek jelentése hasonló, mint *quadprog* esetén.

Nemlineáris programozás (NP):

$[x, fval, exitflag, output, lambda, grad, hessian] = fmincon('fun', x0, A, b, Aeq, beq, lb, ub, 'nonlcon', options)$

ahol a feladat $\min f(x)$, $c(x) \leq 0$, $ceq(x) = 0$, $Ax \leq b$, $Aeq * x = beq$, $lb \leq x \leq ub$, a kezdeti közelítés $x0$, és *options* specifikus előírásokat tartalmaz a kereséshez. A *nonlcon* függvény bemenete x , két kimenete pedig c és ceq . Az első négy kimeneti paraméter jelentése hasonló, mint *quadprog* esetén.

Az Optimization Toolbox függvényei korábban mind az aktív halmaz és a megvalósítható irányok módszerén alapultak. Ez vonatkozott az LP-re is, amely a QP-ben használt módszert alkalmazta. Az újabb verziók lehetővé teszik a belsőpontos módszer használatát is (lásd LMI, Linear Matrix Inequalities, amely a robusztus irányításokhoz szükséges).

A kvázi Newton-módszerek körében alkalmazásra került a BFGS (Broyden-Fletcher-Goldfarb-Shanno) módszer, amely a Hess mátrixot a gradiens értékeiből $\lim_{i \rightarrow \infty} H_i \rightarrow H$ alakkal közelíti, valamint a DFP (Davidon-Fletcher-Powell) módszer és a módosított DFP (Gill&Murray) módszer, amelyek a $\lim_{i \rightarrow \infty} H_i \rightarrow H^{-1}$ alakkal közelítenek. Mindhárom módszer H_{i+1} értékét H_i -ből, valamint a gradiens értékéből határozza meg.

Az NP probléma keretprogramja a Schittkowski által javasolt SQP (Sequential Quadratic Programming) módszert használja, amely BFGS módszerrel frissíti a Lagrange-függvény Hess mátrixát, QP részfeladattal határozza meg a keresési irányt és egy értékelő függvénnyel (merit function) bünteti a korlátozások megsértését az iránymenti keresés során.