

# Struktúrábecslés szubtraktív klaszterezéssel

## Előadás vázlat

Összeállította: Harmati István Ph.D., egyetemi docens

Felhasznált irodalom:

Dr. Lantos Béla: Fuzzy systems and genetic algorithms, 2001, Műegyetemi kiadó, Budapest

### 4.1.2. A szubtraktív klaszterezés algoritmus

1. Az  $x$  és  $y$  változó kvantálása. A Rácsvonalak metszetei adják a  $N_{ij} = (x_i^*, y_j^*)$  rácspontokat.

2. A mintapontok sűrűségének approximációja.

Ehhez a  $M : N_{ij} \rightarrow R^1$  potenciál (vagy hegy) függvény határozzuk meg:

$$d(N_{ij}, (x_k, y_k)) = (x_k - x_i^*)^2 + (y_k - y_j^*)^2,$$

$$M(N_{ij}) = \sum_{k=1}^N \exp\{-\alpha \cdot d(N_{ij}, (x_k, y_k))\}.$$

$M(N_{ij})$  az  $(i, j)$  rácspontban veszi fel a maximumot

3. Inicializálás:  $m := 1$ ,  $M_1 := M$ , az  $\alpha, \beta$  paraméterek megválasztása, a  $\delta > 0$ ,  $(M_{m+1}^* < \delta)$  leállási feltétel beállítása.

4. Ciklus:

i.  $M_m^* := \max_{ij} M_m(N_{ij})$ ,  $N_m^* := \arg \max_{ij} M_m(N_{ij}) = (\bar{x}_m^*, \bar{y}_m^*)$   
 $x_i^*, y_j^*$

(a potenciálfüggvény maximális értéke és helye)

ii. A potenciálfüggvény módosítása (subtracting - kivonás)

$$M_{m+1}(N_{ij}) := M_m(N_{ij}) - M_m^* \exp\{-\beta \cdot d(N_m^*, N_{ij})\}$$

iii. Ha  $M_{m+1}^* \geq \delta$ , akkor Ugrás 4. lépésre, egyébként Stop.

### 4.1.3. A fuzzy rendszer felépítése a szubtraktív klaszterezési algoritmus eredménye alapján

A klaszterek középpontjai:  $N_i^* = (\bar{x}_i^*, \bar{y}_i^*), i = 1, \dots, m$

A fuzzy reláció alakja minden  $N_i^* = (\bar{x}_i^*, \bar{y}_i^*), i = 1, \dots, m$  klaszter középpontra:

$$R_i : \text{if } x \text{ is near } x_i^* \text{ then } y \text{ is near } y_j^*, \quad i = 1, \dots, m.$$

Legyen az  $A_i$  fuzzy halmaz középpontja  $\bar{x}_i := \bar{x}_i^*$

Legyen a  $B_i$  fuzzy halmaz középpontja  $\hat{y}_i := \bar{y}_i^*$  (Sugeno rendszer, ezért ez lesz a szabály tüzelési értéke)

Az  $A_i$  fuzzy halmaz tagsági függvénye legyen Gauss függvény:

$$\mu_{A_i}(x) = \exp\left\{-\frac{1}{2}\left(\frac{x - \bar{x}_i}{\sigma_i}\right)^2\right\} =: \tau_i \quad (\text{A szabály } \hat{y}_i \text{ kimenetének tüzelési súlya})$$

Az approximált kimenet:

$$\hat{y} = \hat{f}(x) = \frac{\sum_{i=1}^m \tau_i \hat{y}_i}{\sum_{i=1}^m \tau_i} = \sum_{i=1}^m \tau_i^* \hat{y}_i$$

ahol  $\tau_i^* = \frac{\tau_i}{\sum_{k=1}^m \tau_k}$

MATLAB megvalósítás: `genfis2`

#### 4.1.4. A fuzzy rendszer feljavítása

A hatékonyságot növelhetjük a  $\bar{x}_i, \sigma_i, \hat{y}_i$  hangolásával (optimumkeresési módszerekkel)

Szigorúan tekintve már nem a szubtraktív klaszeterezés része.

<p>Hiba egy tanítópontnál:</p> $E_k = \frac{1}{2} [y_k - \hat{y}(x_k)]^2$ <p>A totális hiba:</p> $E_{\text{total}} = \sum_{k=1}^N E_k$	<p>Egy <math>p</math> parameter szerinti hangolás:</p> $\frac{\partial E_k}{\partial p} = -[y_k - \hat{y}(x_k)] \frac{\partial \hat{y}(x_k)}{\partial p}$ $\frac{\partial E_{\text{total}}}{\partial p} = \sum_{k=1}^N \frac{\partial E_k}{\partial p}$
<p>Parciális deriváltak a hangoláshoz:</p> $\frac{\partial \hat{y}(x_k)}{\partial \hat{y}_i} = \tau_i^*$ $\frac{\partial \hat{y}(x_k)}{\partial \bar{x}_i} = \hat{y}_i \frac{\partial \tau_i}{\partial \bar{x}_i} \frac{1}{\sum_k \tau_k} + \sum_i \hat{y}_i \tau_i (-1) \frac{1}{(\sum_k \tau_k)^2} \frac{\partial \tau_i}{\partial \bar{x}_i} =$ $= \hat{y}_i \frac{\partial \tau_i}{\partial \bar{x}_i} \frac{1}{\sum_k \tau_k} - \hat{y}(x_k) \frac{1}{\sum_k \tau_k} \frac{\partial \tau_i}{\partial \bar{x}_i}$ $\frac{\partial \tau_i}{\partial \bar{x}_i} = \exp \left[ -\frac{1}{2} \left( \frac{x_k - \bar{x}_i}{\sigma_i} \right)^2 \right] \left( -\frac{1}{2} \right) \frac{1}{\sigma_i^2} 2(x_k - \bar{x}_i)(-1) = \tau_i \frac{x_k - \bar{x}_i}{\sigma_i^2}$ $\frac{\partial \hat{y}(x_k)}{\partial \bar{x}_i} = [\hat{y}_i - \hat{y}(x_k)] \tau_i^* \frac{x_k - \bar{x}_i}{\sigma_i^2}$ $\frac{\partial \hat{y}(x_k)}{\partial \sigma_i} = [\hat{y}_i - \hat{y}(x_k)] \tau_i^* \frac{(x_k - \bar{x}_i)^2}{\sigma_i^3}$	<p>A hangolás <math>e = y_k - \hat{y}(x_k)</math> bevezetése mellett:</p> $\hat{y}_i := \hat{y}_i + \gamma e \tau_i^*$ $\bar{x}_i := \bar{x}_i + \gamma e [\hat{y}_i - \hat{y}(x_k)] \tau_i^* (x_k - \bar{x}_i) / \sigma_i^2$ $\sigma_i := \sigma_i + \gamma e [\hat{y}_i - \hat{y}(x_k)] \tau_i^* (x_k - \bar{x}_i)^2 / \sigma_i^3$